Regolarizzazione sparsa

Antonio Carboncino
Libera Pasqualina Ciambriello
Alessia Coppola
Greta Porzio

20 Febbraio 2026

Idea: un'immagine può essere ben approssimata usando pochi coefficienti "importanti" in una base adatta.
Considerata una base ortogonale,

$$B = \{\psi_m\}_m \tag{1}$$

vogliamo combinarne gli elementi per approssimare opportunamente un'immagine f.

Per misurare quanto è semplice quest'approssimazione, introduciamo un **prior di sparsità ideale**:

$$J_0(f) \stackrel{\text{def}}{=} |\{m \ : \ \langle f, \psi_m \rangle \neq 0\}| \tag{2}$$

dove

$$x_m = \langle f, \psi_m \rangle \tag{3}$$

sono i coefficienti e ci danno informazione su quanto ciascun elemento della base contribuisce all'immagine.

Il *prior di sparsità* conta quanti coefficienti sono diversi da 0, ignorandone il valore.
Per questo motivo è detta anche **pseudo-norma** l_0 e si scrive anche:

$$\|x\|_{\ell^0} \stackrel{\text{def}}{=} J_0(f) \tag{4}$$

Tale quantità è usata come misura ideale di sparsità.

Le immagini naturali non sono esattamente sparse però possono essere ben approssimate usando pochi coefficienti significativi.

- Se $J_0(f)$ è piccolo, significa che l'immagine è *quasi sparsa*.

L'approssimazione migliore si ottiene per un certo numero M di coefficienti

$$f_M = \sum_{m:\,|\langle f,\psi_m\rangle|>T} \langle f, \psi_m \rangle \, \psi_m \tag{5}$$

dove

$$M = \#\left\{m : |\langle f, \psi_m \rangle| > T\right\}. \tag{6}$$

con T valore di soglia fissato.

Rilassamento convesso

Il problema nasce col fatto che $J_0(f)$ non è convesso.
Infatti, se consideriamo due funzioni f e g con coefficienti non nulli in posizioni differenti, allora:

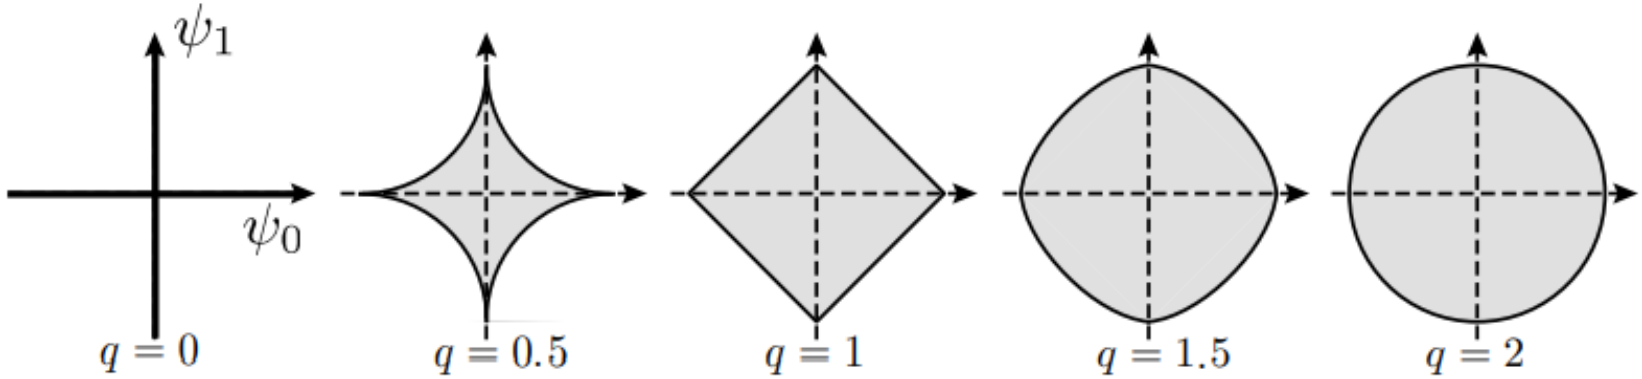
$$J_0\left(\frac{f+g}{2}\right) = J_0(f) + J_0(g) \tag{7}$$

Tale relazione mostra che J_0 non soddisfa la disuguaglianza di convessità e che, quindi, **minimizzare J_0 è un problema intrattabile per situazioni reali** (deblurring, denoising,...)

Invece di usare J_0, introduciamo una famiglia di *prior*, $J_q(f)$, con l'obiettivo di approssimarlo:

$$J_q(f) = \sum_m |\langle f, \psi_m \rangle|^q, \qquad q > 0. \tag{8}$$

Osserviamo che:



- $q \to 0$: si avvicina al prior ideale J_0
- $q = 1$: massimo grado di sparsità con convessità
- $q > 1$: penalizzazione meno sparsificante

Il *prior* J_q è convesso **se e solo se** $q \geq 1$. Per raggiungere il massimo grado di sparsità usando un prior convesso, consideriamo il prior J_1 in l^1, definito come segue

$$J_1(f) = \sum_m |\langle f, \psi_m \rangle| = \|\{\langle f, \psi_m \rangle\}\|_{\ell^1} \tag{9}$$

questo è il rilassamento convesso di J_0.

Sparse Regularization e Thresholding

Consideriamo un problema di *denoising*:

$$f^* = argmin_{g \in \mathbb{R}^N} \left(\frac{1}{2} \|f - g\|^2 + \lambda J_q(g) \right) \tag{10}$$

dove

- **g** è l'immagine osservata;
- **f** è il segnale pulito che vogliamo stimare;
- λ bilancia fedeltà e regolarizzazione.

In questo caso, $q = 0$ oppure $q = 1$.
Per $q = 0$ supponiamo che, $\forall u \in \mathbb{R}$

$$|u|^0 = \begin{cases} 0 & \text{se } u = 0, \\ 1 & \text{se } u \neq 0. \end{cases} \tag{11}$$

Possiamo riscrivere il problema nella base ortogonale, come

$$f^* = \sum_m x_m^* \psi_m \tag{12}$$

dove

$$x_m^* = \arg\min_{y \in \mathbb{R}^N} \sum_m \frac{1}{2}|x_m - y_m|^2 + \lambda |y_m|^q \tag{13}$$

con

$$x_m = \langle f, \psi_m \rangle, \;\; y_m = \langle g, \psi_m \rangle \tag{14}$$

Grazie all'ortonormalità, il problema si separa coefficiente per coefficiente. **Riusciamo**, a partire da un problema N-dimensionale, **ad ottenere N-problemi 1-dimensionale indipendenti**.
Ogni coefficiente dell'immagine priva di rumore è soluzione di un problema di ottimizzazione 1-dimensionale

$$x_m^* = \arg\min_{u \in \mathbb{R}} \frac{1}{2}|x_m - u|^2 + \lambda |u|^q \tag{15}$$

Proposizione:La soluzione del problema (15) ha una forma chiusa

$$x_m^* = S_T^q(x_m) \tag{16}$$

dove

$$T = \begin{cases} \sqrt{2\lambda} & \text{se } q = 0, \\ \lambda & \text{se } q = 1. \end{cases} \tag{17}$$

In particolare,

$$\forall u \in \mathbb{R}, \qquad S_T^0(u) = \begin{cases} 0 & \text{se} |u| < T \\ u & \text{altrimenti} \end{cases} \tag{18}$$

elimina brutalmente i coefficienti piccoli, lascia invariati gli altri (**Hard thresholding**).
Invece,

$$\forall u \in \mathbb{R}, \qquad S_T^1(u) = sign(u)\,(|u| - T)_+ \tag{19}$$

ci dice che i coefficienti piccoli vanno a zero e quelli grandi vengono ridotti (**Soft thresholding**).

Comparison of Denoising with $q = 0$ vs. $q = 1$



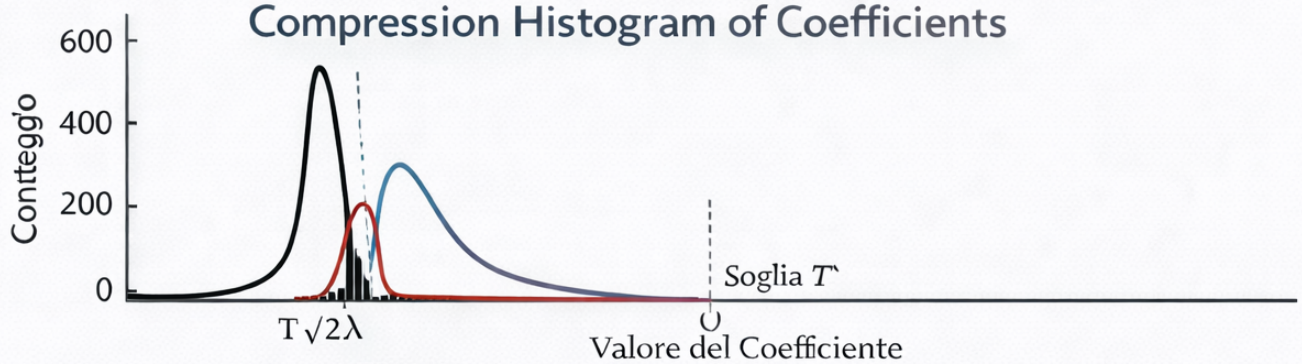
No Thresholding



Soft Thresholding ($q = 1$)



Hard Thresholding ($q = 0$)



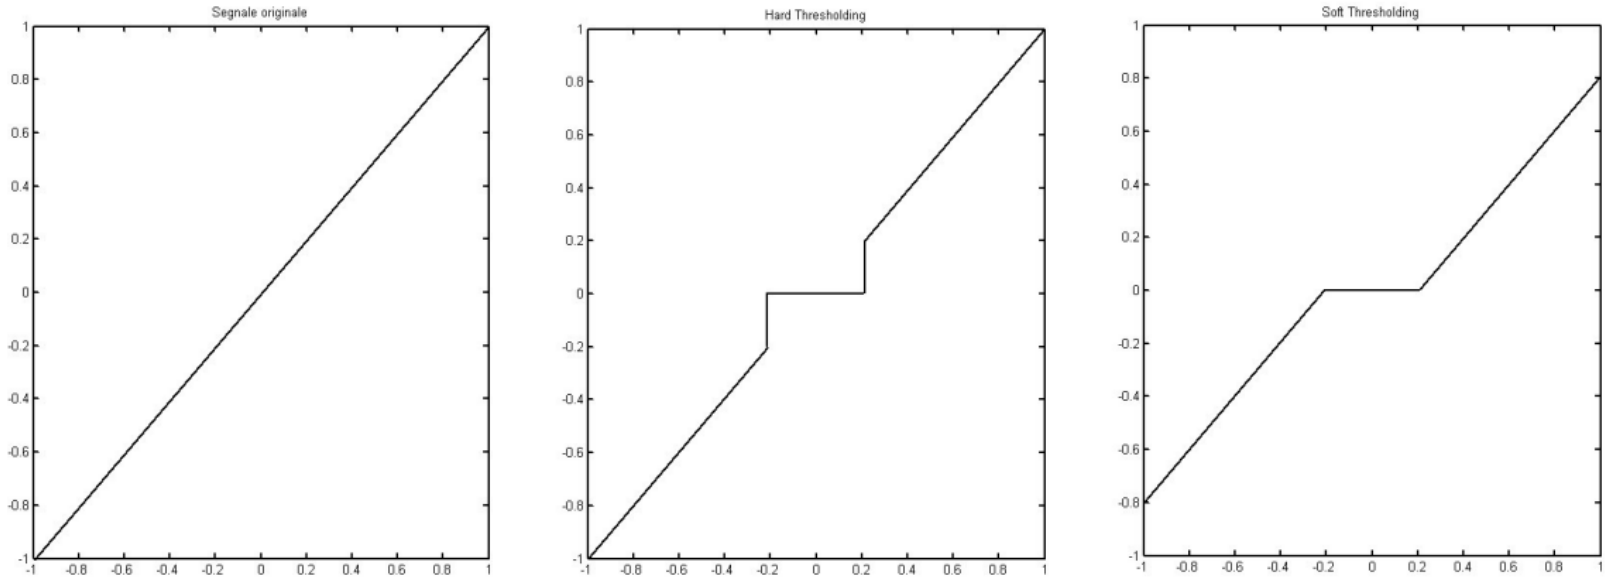


Figure: Soft e hard thresholding di una wavelet in Matlab

L'hard thresholding consiste nel classico procedimento di portare a zero tutti quei valori il cui modulo è minore della soglia fissata; il soft thresholding, oltre a questo primo passo, sposta verso lo zero i coefficienti non nulli in modo da eliminare le discontinuità introdotte nel primo caso.

	SOFT THRES.	**HARD THRES.**
penalizzazione	lineare	convessa
convessità	convessa	non convessa
stabilità	stabile	instabile
continuità	continua	discontinua
effetto sui grandi coefficienti	ridotti	invariati
artefatti	pochi	possibili

Questi metodi di denoising ci permettono di fissare semplicemente la soglia per gaussiane con rumore ω e varianza σ^2. Teoricamente, il valore

$$T = \sqrt{2log(N)}\sigma \tag{20}$$

è asintoticamente ottimale. In pratica si usa:

- $T \approx 3\sigma$ per *hard thresholding*(l^0);
- $T \approx \frac{3}{2}\sigma$ per *soft thresholding* (l^1).

Regolarizzazione sparsa e problemi inversi

Supponiamo di avere un segnale f sparso in una certa base ortogonale $\{\psi_m\}_m$ di $\mathbb{R}^N$ in norma l^1.
Facendo uso del J_1 definito in precedenza, si risolve il seguente problema convesso inverso:

$$f_\lambda \in \arg\min_{f\in\mathbb{R}^N} \frac{1}{2}\|y-\Phi f\|^2 + \lambda \sum_m |\langle f, \psi_m\rangle| \tag{21}$$

Quando il set di atomi $\Psi = \{\psi_m\}_{m=1}^{Q}$ non è ortogonale (potrebbe anche essere ridondante, nel caso in cui $Q > N$), nascono due *prior* diversi:

- **Prior di analisi**

$$\Psi^* : f \in \mathbb{R}^N \rightarrow (\langle f, \psi_m \rangle)_{m=1}^{Q} \in \mathbb{R}^{\mathbb{Q}} \tag{22}$$

I *prior di analisi* ci permettono di misurare la scarsità delle correlazioni con gli atomi nel dizionario

$$J_1^A(f) \stackrel{\text{def}}{=} \sum_m |\langle f, \psi_m \rangle| = \|\Psi^* f\|_1 \tag{23}$$

In questo modo guardiamo le correlazioni di f con gli atomi e "penalizziamo" se ce ne sono molte attive.

- **Prior di sintesi**

$$\Psi : x \in \mathbb{R}^{\mathbb{Q}} \rightarrow \psi x = \sum_{m} x_m \psi_m \tag{24}$$

Assumiamo f costruito come combinazione sparsa degli atomi

$$J_1^S(f) \stackrel{\text{def}}{=} \min_{x \in \mathbb{R}^Q, \Psi x = f} \|x\|_1 \tag{25}$$

I *prior di sintesi*, al contrario, cercano la rappresentazione più sparsa di f, lavorando direttamente sui coefficienti x.

Scegliendo il *prior di sintesi*, riscriviamo convenientemente $f_\lambda = \Psi x_\lambda$ e risolviamo il seguente problema (che è ancora un problema di denoising, ma sui coefficienti)

$$x_\lambda \in \arg\min_{x \in \mathbb{R}^Q} \frac{1}{2\lambda}\|y - Ax\|^2 + \|x\|_1 \tag{26}$$

supponendo di aver introdotto la seguente matrice

$$A \stackrel{\text{def}}{=} \Phi\Psi \in \mathbb{R}^{P \times Q} \tag{27}$$

Quando $\lambda \to 0$

$$x^* = \arg\min_{Ax=y} \|x\|_1 \tag{28}$$

La ricostruzione finale è del tipo $f^* = \Psi x^* \in \mathbb{R}^N$ e ci permette di cercare la soluzione più sparsa compatibile con i dati.

Caso senza rumore: formulazione come programma lineare

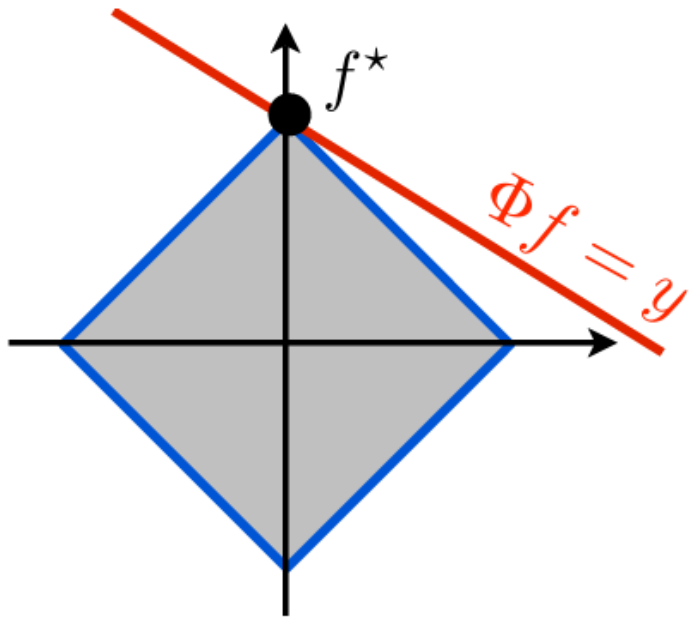
Nel caso senza rumore, stiamo assumendo il modello esatto per cui $y = Ax_0$ per qualche x_0.

In questo caso il problema generale

$$x^\star = \arg\min_{x \in \mathbb{R}^Q} \frac{1}{2} \|y - Ax\|^2 + \lambda \|x\|_1 \tag{29}$$

diventa

$$x^\star = \arg\min_{Ax=y} \|x\|_1. \tag{30}$$



Ma ,poiché $x = x^+ - x^-$ e $\|x\|_1 = x^+ + x^-$, si può riscrivere la (30) come segue:

$$x^\star = \arg \min_{(x^+,x^-)\in(\mathbb{R}_+^Q)^2} \left\{ \langle x^+, \mathbf{1}_Q \rangle + \langle x^-, \mathbf{1}_Q \rangle \ ; \ y = A(x^+ - x^-) \right\} \tag{31}$$

Poiché la (31) è un problema di ottimizzazione con funzione obiettivo lineare e vincoli lineari, il caso senza rumore è un programma lineare (LP), che può quindi essere risolto, in teoria, con i classici algoritmi LP.

Tuttavia, gli algoritmi per la programmazione lineare hanno una complessità tipicamente dell'ordine di $\mathcal{O}(Q^3)$. Per problemi di grandi dimensioni (ad esempio in imaging o machine learning), tali metodi risultano impraticabili sia in termini di tempo che di memoria.

Tuttavia, gli algoritmi per la programmazione lineare hanno una complessità tipicamente dell'ordine di $\mathcal{O}(Q^3)$. Per problemi di grandi dimensioni (ad esempio in imaging o machine learning), tali metodi risultano impraticabili sia in termini di tempo che di memoria.

Per ovviare a questo problema, si risolve il problema generale mediante algoritmi più efficienti (ad es. ISTA) e si considera *concettualmente* il limite della soluzione ottenuta per $\lambda \to 0$.

Caso generale: un primo algoritmo

Consideriamo sempre il problema di ottimizzazione generale

$$x^\star = \arg\min_{x\in\mathbb{R}^Q} \frac{1}{2}\|y - Ax\|^2 + \lambda\|x\|_1. \tag{32}$$

Un primo modo per risolverlo è applicare il cosiddetto **Metodo del gradiente proiettato**. Questo algoritmo è pensato per un problema di ottimizzazione del tipo

$$\arg\min_{u\in C} E(u) \tag{33}$$

con $E(u)$ funzione reale convessa e C^1 e C insieme convesso e chiuso.

Per ovviare al problema della non differenziabilità in tutti i punti della (32) e applicare poi l'algoritmo, si usa nuovamente il trucco: $x = x^+ - x^-$ e $\|x\|_1 = x^+ + x^-$. Ponendo poi $u^+ = x^+$ e $u^- = x^-$, la funzione da minimizzare diventa:

$$E(u^+, u^-) = \frac{1}{2} \|A(u^+ - u^-) - y\|^2 + \lambda \langle u^+, \mathbf{1}_Q \rangle + \lambda \langle u^-, \mathbf{1}_Q \rangle \quad (34)$$

con il vincolo

$$(u^+, u^-) \in C \quad \text{dove} \quad C = (\mathbb{R}_+^Q)^2.$$

In questa nuova formulazione del problema, tutte le ipotesi teoriche per applicare l'algoritmo sono rispettate.

Esplicitiamo allora il gradiente di $E(u^+, u^-)$ e la proiezione di (u^+, u^-) sull'insieme C:

$$\nabla E(u^+, u^-) = \big(\eta + \lambda \mathbf{1}_Q,\ -\eta + \lambda \mathbf{1}_Q\big), \quad \text{con} \quad \eta = A^*\big(A(u^+ - u^-) - y\big) \tag{35}$$

e

$$\mathrm{Proj}_{(\mathbb{R}_+^Q)^2}(u^+, u^-) = \big((u^+)^\oplus, (u^-)^\oplus\big), \quad \text{con} \quad (r)^\oplus = \max(r, 0). \tag{36}$$

Seguendo il metodo del gradiente proiettato, a questo punto costruiamo le iterazioni seguenti:

$$u_+^{(\ell+1)} \stackrel{\text{def}}{=} \left(u_+^{(\ell)} - \tau^{(\ell)}(\eta^{(\ell)} + \lambda)\right)^{\oplus} \tag{37}$$

$$u_-^{(\ell+1)} \stackrel{\text{def}}{=} \left(u_-^{(\ell)} - \tau^{(\ell)}(-\eta^{(\ell)} + \lambda)\right)^{\oplus} \tag{38}$$

avendo posto

$$\eta^{(\ell)} \stackrel{\text{def}}{=} A^*\left(A(u_+^{(\ell)} - u_-^{(\ell)}) - y\right) \tag{39}$$

e avendo scelto ad ogni iterazione accuratamente $\tau^{(\ell)}$, in maniera tale da avere:

$$\forall\, \ell, \qquad 0 < \tau_{\text{min}} < \tau^{(\ell)} < \tau_{\text{max}} < \frac{2}{\|A\|^2}. \tag{40}$$

La scelta apposita degli $\tau^{(\ell)}$ garantisce la convergenza di $u_-^{(\ell)}$ e $u_+^{(\ell)}$,rispettivamente, ai vettori $u_-^\star$ e $u_+^\star$ tali che

$$x^\star \stackrel{\text{def}}{=} u_+^\star - u_-^\star$$

sia una soluzione del problema generale (32).

Caso generale: l'algoritmo definitivo

Lo svantaggio principale dell'algoritmo precedente è quello di dover memorizzare ogni volta $2Q$ coefficienti anziché Q. Questo problema non si ha più nell'algoritmo **ISTA (Iterative Soft Thresholding Algorithm)**, un algoritmo che costruisce iterazioni che tendono a una soluzione di (32) con la stessa velocità di convergenza del metodo precedente.

Riscriviamo la funzione obiettivo da minimizzare:

$$E(x) \stackrel{\text{def}}{=} \frac{1}{2}\|y - Ax\|^2 + \lambda\|x\|_1. \tag{41}$$

Per ogni fissato $\tilde{x}$, introduciamo la funzione:

$$E_\tau(x, \tilde{x}) \stackrel{\text{def}}{=} E(x) - \frac{1}{2}\|Ax - A\tilde{x}\|^2 + \frac{1}{2\tau}\|x - \tilde{x}\|. \tag{42}$$

Ponendo poi

$$K(x, \tilde{x}) \stackrel{\text{def}}{=} -\frac{1}{2}\|Ax - A\tilde{x}\|^2 + \frac{1}{2\tau}\|x - \tilde{x}\|^2 = \frac{1}{2}\left\langle \left(\tfrac{1}{\tau} I_N - A^* A\right)(x - \tilde{x}),\, x - \tilde{x}\right\rangle \tag{43}$$

si osserva che se $\tau < \frac{1}{\|A\|_{\text{op}}^2}$, allora $K(x, \tilde{x}) \geq 0$ per ogni x.

In queste ipotesi di τ, $E_\tau(x, \tilde{x})$ è maggiore o uguale di $E(x)$ in tutti i punti ed è quindi sensato, nonché ben posto, costruire le iterazioni come segue:

$$x^{(n+1)} \stackrel{\text{def}}{=} \arg\min_x E_{\tau_l}\left(x, x^{(n)}\right) \tag{44}$$

avendo cura sempre di scegliere i τ_l che rispettano l'ipotesi suddetta.

Osserviamo che queste iterazioni ci permettono di ridurre sempre di più $E(x)$; infatti per definizione di minimo si ha che

$$E_{\tau_l}(x^{l+1}, x^l) \leq E_{\tau_l}(x^l, x^l). \tag{45}$$

Ma poiché

$$E_{\tau_l}(x^l, x^l) = E(x^l) \tag{46}$$

e, per la maggiorazione suddetta,

$$E(x^{l+1}) \leq E_{\tau_l}(x^{l+1}, x^l) \tag{47}$$

mettendo tutto insieme, si ha che:

$$E(x^{l+1}) \leq E_{\tau_l}(x^{l+1}, x^l) \leq E(x^l) \tag{48}$$

E' possibile attraverso la proposizione seguente esprimere anche le iterazioni di ISTA in forma chiusa.

Proposizione: Le iterazioni dell'algoritmo ISTA soddisfano:

$$x^{(l+1)} = S^1_{\lambda\tau_l}\left(x^{(l)} - \tau_l A^*\left(Ax^{(l)} - y\right)\right) \tag{49}$$

con $S^1_{\lambda\tau_l}(x) = (S^1_{\lambda\tau_l}(x_m))_m$ e
$S^1_{\lambda\tau_l}(r) = S^1_T(u) = sign(u)\left(|u| - \lambda\tau_l\right)_+$, che è l'operatore di soft thresholding.

Osserviamo esplicitamente che il termine più interno fa muovere le iterazioni verso soluzioni che si allontano meno dall'osservazione y e che, quindi, sono più fedeli ai dati. Invece l'operatore di soft thresholding ha il ruolo di tagliare via i coefficienti considerati troppo piccoli e, garantire, una maggiore sparsità delle iterazioni.

Esempi e applicazioni: Sparse Deconvolution

La sparse deconvolution è un problema inverso in cui si vuole ricostruire un segnale a partire da una versione convoluta e rumorosa, assumendo che il segnale originale sia sparso in una certa base.
Il segnale viene quindi osservato come segue:

$$y = h * f_0 + w \tag{50}$$

con

- y = dato osservato
- h = filtro
- f_0 = segnale originale
- w = rumore.

Un caso specifico è quello della **Sparse Spikes Deconvolution**. In questo problema, il concetto di sparsità è da intendersi come sparsità nel dominio spaziale, perchè la base ortogonale che si considera è la base dei Dirac discreta:

$$\psi_m[n] = \delta[n - m]$$

cioè la base canonica di $\mathbb{R}^N$.
La sparsità del segnale in questo caso significa quindi che f_0 ha pochi coefficienti non nulli.

Un caso specifico è quello della **Sparse Spikes Deconvolution**. In questo problema, il concetto di sparsità è da intendersi come sparsità nel dominio spaziale, perchè la base ortogonale che si considera è la base dei Dirac discreta:

$$\psi_m[n] = \delta[n - m]$$

cioè la base canonica di $\mathbb{R}^N$.
La sparsità del segnale in questo caso significa quindi che f_0 ha pochi coefficienti non nulli.
Un campo di applicazione della Sparse Spikes Deconvolution è la sismologia. Infatti, nel contesto dell' imaging del sottosuolo, il segnale originale rappresenta le variazioni di densità del terreno ed è modellato come somma di pochi impulsi di Dirac. In questo caso h rappresenta il segnale invece inviato nel terreno.

Schematizzando, come problema inverso si ha:

$$f^* = \arg\min_{f \in \mathbb{R}^N} \frac{1}{2}\|f * h - y\|^2 + \lambda \sum |f_m|. \tag{51}$$

E, come componenti delle iterazioni date dall'algoritmo ISTA, si ha:

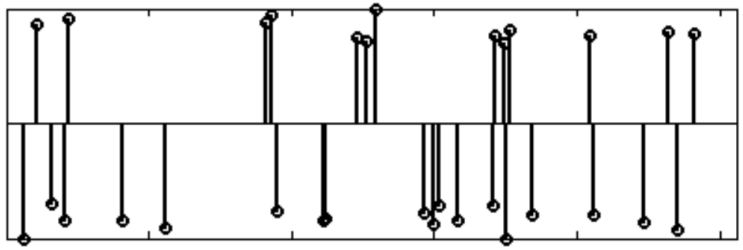
$$f_m^{(k+1)} = S_{\lambda\tau}^{(1)}\left(\tilde{f}_m^{(k)}\right) \tag{52}$$

con

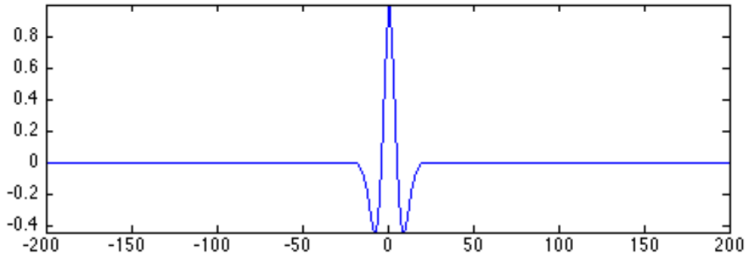
$$\tilde{f}^{(k)} = f^{(k)} - \tau\, h * \left(h * f^{(k)} - y\right) \tag{53}$$

e, con condizione sul passo:

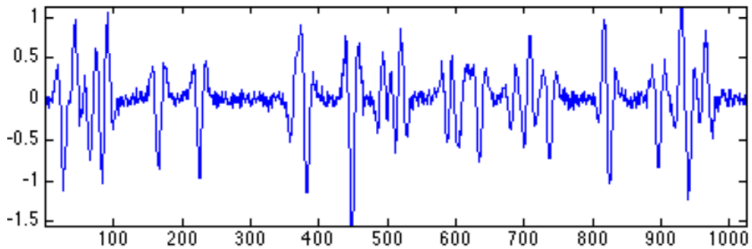
$$\tau < \frac{1}{\max_\omega |\hat{h}(\omega)|^2}. \tag{54}$$



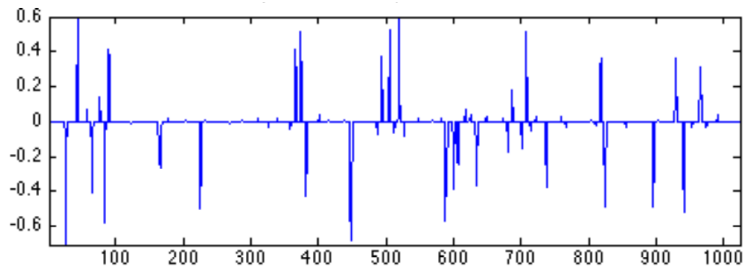
f_0



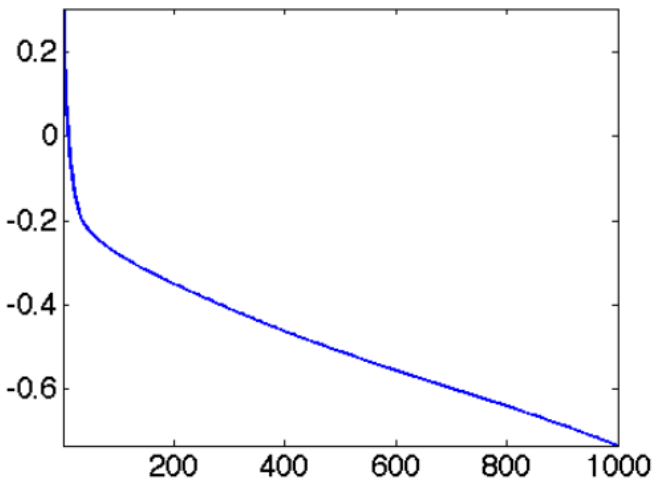
h



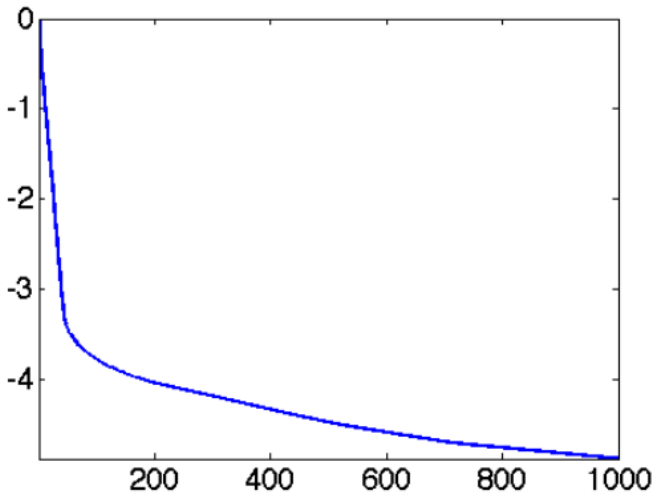
$y = h \star f + w$



$f^\star$



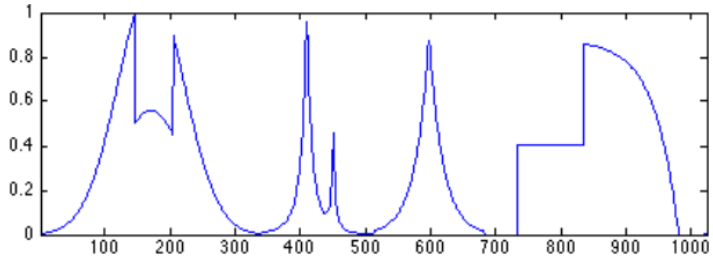
$\log_{10}(E(f^{(k)})/E(f^\star) - 1)$



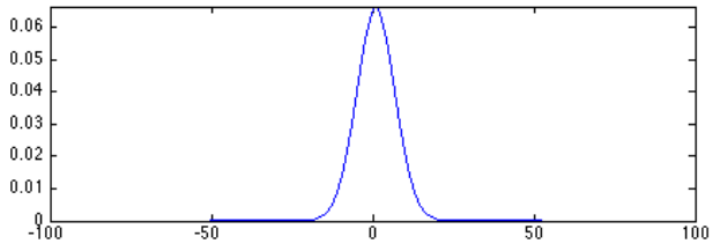
$\log_{10}(\|f^{(k)} - f^\star\|/\|f_0\|)$

Figure 9.6: Decay of the energy and convergence through the iterative thresholding iterations.

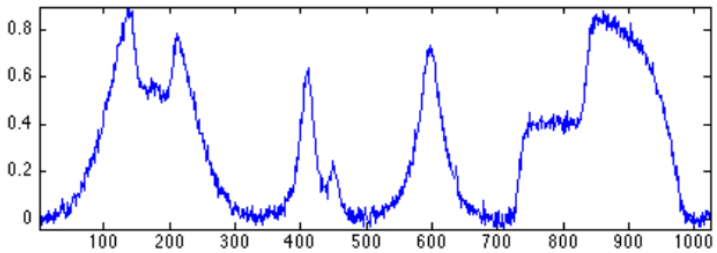
Un altro caso specifico è quello della **Sparse Wavelet Deconvolution**, che, come base, usa delle Wavelet ortogonali. La maggiore applicazione di questo metodo è nel campo delle immagini, dove appunto f_0 rappresenta l'immagine originale e h in genere un certo filtro di sfocatura.
Come esempio portiamo un caso di ricostruzione dell'immagine iniziale, che era stata sfocata da un filtro Gaussiano.



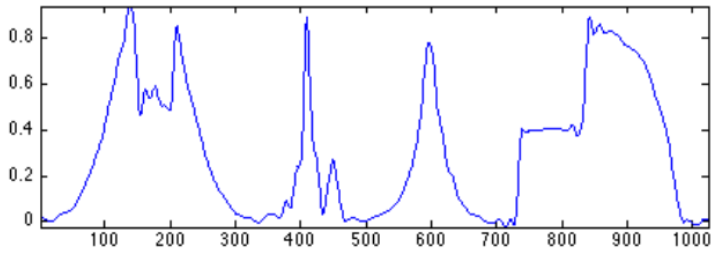
Signal f_0



Filter h



Observation $y = h \star f_0 + w$



ℓ^1 recovery $f^\star$



Image f_0



Observations $y = h \star f_0 + w$



ℓ^1 regularization